

Online Convex Optimization for Constrained Control of Nonlinear Systems

在线凸优化与参考调节器：非线性系统的约束控制

Hazhy

Paper Review

2026-05-28

论文信息

- **标题:** Online convex optimization for constrained control of nonlinear systems
- **作者:** Marko Nonhoff, Johannes Köhler, Matthias A. Müller
- **期刊:** Automatica 188 (2026) 112916
- **机构:** Leibniz University Hannover & ETH Zürich
- **关键词:** Online convex optimization, Control of constrained systems, Nonlinear systems, Dynamic regret, Reference governor

研究动机：为什么需要 OCO + 控制？

核心挑战：

- 代价函数 $L_t(x, u)$ 是时变且先验未知的
- 系统具有非线性动力学和状态/输入约束
- 必须在每步仅基于历史信息做出决策

现有方法不足：

- Nonstochastic Control：仅限于线性系统、扰动抑制
- Feedback Optimization：仅保证渐近约束满足
- 已有 OCO-based 方法：受限于特定算法，regret 界次优

本文贡献：模块化的 OCO-RG 框架，适用于非线性系统，保证严格约束满足，达到最优 regret 界

问题建模：非线性的在线最优控制

非线性动力学系统：

$$x_{t+1} = f(x_t, u_t), \quad t \in \mathbb{N}$$

- $x_t \in \mathbb{R}^n$ ：系统状态
- $u_t \in \mathbb{R}^m$ ：控制输入

约束条件：

$$(x_t, u_t) \in \mathcal{Z}, \quad t \in \mathbb{N}$$


在线最优控制问题（OCO 视角）：

$$\min_{u_0, \dots, u_T} \sum_{t=0}^T L_t(x_t, u_t) \quad \text{s.t. } x_{t+1} = f(x_t, u_t), (x_t, u_t) \in \mathcal{Z}$$

关键难点： L_t 在第 t 步完成后才被揭示，决策 u_t 只能依赖 $L_0, \dots, L_{t-1}$ 和状态 x_t 。

OCO-RG 框架：三大模块

核心思想：将在线优化与约束控制解耦，通过模块化设计实现灵活性和理论保证。



三大组件：

1. **OCO 算法：**基于历史代价计算期望参考 r_t
2. **参考调节器 (RG)：**修正 r_t 为 v_t ，确保约束满足
3. **稳定反馈控制器：** $u_t = g(x_t, v_t)$ ，跟踪修正后的参考

核心假设：稳态映射与稳定性

Assumption 1 —— 稳态映射：

$$h(v) = f(h(v), g(h(v), v)), \quad \forall v \in \mathbb{R}^o$$

参考输入 v 参数化系统的稳态。线性系统 $f(x, u) = Ax + Bu$ 下： $h(v) = (I_n - AK)^{-1}Bv$ 。标准假设，广泛使用。

Assumption 2 —— Lipschitz 连续性：

$$\|f_g(x, v) - f_g(\tilde{x}, \tilde{v})\| \leq \ell_f \|(x, v) - (\tilde{x}, \tilde{v})\|, \quad \text{类似地 } g, h$$

Assumption 3 —— 指数稳定性：

$$\|\phi(x, v, t) - h(v)\| \leq c\|x - h(v)\|\rho^t, \quad \rho \in [0, 1), \quad c \geq 1$$

关键保证： 闭环系统指数收敛到稳态，这是 regret 分析的基础。

参考调节器 (RG): 安全屏障

Assumption 4 —— 安全集 $\mathcal{O}$:

$$(x, v) \in \mathcal{O} \implies (\phi(x, v, t), v) \in \mathcal{Z}_g, \forall t \in \mathbb{N}$$

$\mathcal{O}$ 是前向不变的: 一旦进入, 恒定参考信号下永不会违反约束。

Assumption 5 —— RG 行为:

$$\begin{cases} v_t = r_t, & \text{if } r_t \in \mathcal{O}_v(x_t) \\ \lVert v_t - v_{t-1} \rVert \geq \kappa_t, \lVert r_t - v_t \rVert \leq (1 - \delta(\kappa_t)) \lVert r_t - v_{t-1} \rVert, & \text{otherwise} \end{cases}$$

Scalar RG (最常用):

$$\begin{aligned} \kappa_t &= \arg \max_{\alpha \in [0,1]} \alpha \text{ s.t. } (x_t, v_{t-1} + \alpha(r_t - v_{t-1})) \in \mathcal{O} \\ v_t &= v_{t-1} + \kappa_t(r_t - v_{t-1}) \end{aligned}$$

OCO 算法：在线跟踪时变最优

稳态代价函数：

$$L_t^s(v) := L_t(h(v), g(h(v), v))$$

简化的 OCO 问题：

$$\min_{r_0, \dots, r_T \in \mathcal{S}_v} \sum_{t=0}^T L_t^s(r_t)$$

关键简化：通过稳态映射 h ，将带动力学的控制问题转化为标准 OCO 问题！

最优参考 (benchmark, 仅用于分析)：

$$\theta_t := \arg \min_{v \in \mathcal{S}_v} L_t^s(v)$$

Definition 1 —— OCO 的 Dynamic Regret 和 Path Length：

$$R_T^{\text{OCO}} := \sum_{t=0}^T [L_t^s(r_t) - L_t^s(\theta_t)], \quad R_T^{\text{PL}} := \sum_{t=1}^T \|r_t - r_{t-1}\|$$

注意：Path length R_T^{PL} 在 regret 界中起关键作用！

完整算法：OCO-RG Framework

Algorithm 1: The OCO-RG Framework

for $t \in \mathbb{N}$ **do**

Given measurement x_t

$r_t = \mathcal{A}_{\text{OCO}}(\mathcal{J}_t)$;

// OCO 计算期望参考

$v_t = \text{RG}(x_t, r_t)$;

// RG 修正以确保安全

 Apply $u_t = g(x_t, v_t)$;

// 反馈控制器执行

信息集: $\mathcal{J}_t := \{r_0, \dots, r_{t-1}, L_0, \dots, L_{t-1}\}$

模块化优势:

- OCO 算法可任意替换 (OGD、Frank-Wolfe、二阶方法等)
- RG 可任意替换 (Scalar RG、Command Governor 等)
- 控制器可任意替换 (满足指数稳定性即可)

辅助工具：Lyapunov 函数与参考变化的影响

Lemma 1 —— Lyapunov 函数存在性：

$$\gamma_1 \|x - h(v)\| \leq V(x, v) \leq \gamma_2 \|x - h(v)\|$$

$$V(f_g(x, v), v) - V(x, v) \leq -\gamma_3 \|x - h(v)\|$$

$$|V(x, v) - V(x, \tilde{v})| \leq \ell_v \|v - \tilde{v}\|$$

Lemma 2 —— 参考变化的累积影响：

$$V(x_{\tau_2}, v_{\tau_2}) \leq \tilde{\rho}^{\tau_2 - \tau_1} V(x_{\tau_1}, v_{\tau_1}) + \ell_v \sum_{i=\tau_1+1}^{\tau_2} \|v_i - v_{i-1}\| \tilde{\rho}^{\tau_2 - i}$$

物理意义：当参考 v 改变时，Lyapunov 函数受两项影响——旧状态的指数衰减 + 参考变化累积。

Lemma 3: 平均收敛保证

核心问题: RG 可能在多步内阻止参考更新 ($v_t \neq r_t$), 我们需要保证”平均而言”参考在推进。

Lemma 3 —— 有限时间平均收敛:

$$\exists M \in \mathbb{N}, \delta \in (0, 1] \text{ s.t. } \prod_{i=t}^{t+M} (1 - \delta(\kappa_i)) \leq 1 - \delta$$

其中

$$\kappa_i = \begin{cases} \delta^{-1}(\|v_i - v_{i-1}\|), & \text{if } r_i \neq v_i \\ 0, & \text{otherwise} \end{cases}$$

直觉: 在任意 M 步窗口内, RG 至少推进了”一定量”的参考更新。这是连接 RG 行为和 OCO 性能的关键桥梁。

主定理: Dynamic Regret 上界

Theorem. 设 *Assumptions 1–6* 成立。闭环系统满足约束 $(x_t, u_t) \in \mathcal{Z}$ 对所有 $t \in \mathbb{N}$ 。且动态 regret 满足:

$$R_T \leq C_0 + R_T^{OCO} + C_{PL} R_T^{PL}$$

其中

$$C_{PL} = \ell_s \frac{2M + \delta}{\delta} + \ell(1 + \ell_g) \frac{\ell_V}{\gamma_1(1 - \tilde{\rho})},$$
$$C_0 = \ell(1 + \ell_g) \frac{\gamma_2}{\gamma_1(1 - \tilde{\rho})} (\|x_0 - h(\theta_0)\| + \ell_h \|v_0 - \theta_0\|)$$

解释: 框架的 regret 被 OCO 算法本身的 regret $\mathbf{R}_T^{OCO}$ 和 path length $\mathbf{R}_T^{PL}$ 线性地控制。常数取决于 RG 的设计参数 (M, δ) 和控制器收敛速度 $(\tilde{\rho})$ 。

Proposition 2: 线性依赖的最优性

问题: 主定理中 regret 对 R_T^{OCO} 的线性依赖能否改进为次线性?

Theorem (Proposition 2). 对任意控制算法 $u_t = \mathcal{A}(x_0, \dots, x_t, u_0, \dots, u_{t-1}, L_0, \dots, L_{t-1})$ 和任意 OCO 算法 $r_t = \mathcal{A}_{\text{OCO}}(\mathcal{I}_t)$, 存在一系列强凸且 Lipschitz 连续的代价函数 L_t , 使得:

$$R_T(x_0, u_0, \dots, u_T) \geq R_T^{\text{OCO}}(r_0, \dots, r_T)$$

证明思路: 选择 $L_t(x, u) = \left\| \begin{bmatrix} x - h(r_t) \\ u - g(h(r_t), r_t) \end{bmatrix} \right\|^2$, 则 $L_t^s(r_t) = 0$ 而 $L_t(x_t, u_t) \geq 0$, 导致 $R_T \geq R_T^{\text{OCO}}$ 。

结论: 线性上界不可改进, 是最优的。

推论：Q-线性收敛 OCO 算法

Proposition 1 —— Q-线性收敛 $\implies$ 有界 Path Length:

$$\|r_t - \theta_{t-1}\|_S \leq \lambda \|r_{t-1} - \theta_{t-1}\|_S, \quad \lambda \in [0, 1)$$

$\implies R_T^{\text{OCO}}$ 和 R_T^{PL} 都线性地被 $\sum \|\theta_t - \theta_{t-1}\|$ 控制。

Corollary. 若 OCO 算法 Q-线性收敛，则：

$$R_T \leq C_0 + (\tilde{C}_{\text{OCO}} + C_{\text{PL}} \tilde{C}_{\text{PL}}) \sum_{t=1}^T \|\theta_t - \theta_{t-1}\|$$

这是一个最优界！Li et al. (2019) 证明 $\sum \|\theta_t - \theta_{t-1}\|$ 是 regret 的下界。本文在非线性约束系统上达到了与线性系统相同的最优界。

满足条件的算法：Projected OGD（弱拟强凸代价）、Prev. Opt. ($\lambda = 0$) 等。

Remark 3: 与 OCO with Memory 的联系

OCO-M 问题: 代价函数可依赖过去 p 步的决策

$$\min_{\{u_t\}} \sum_{t=0}^T L_t(u_{t-p}, \dots, u_t) \quad \text{s.t. } u_t \in \mathcal{U}$$

转化为 OCO-RG 框架:

- 定义状态 $x_t = [u_{t-p} \cdots u_{t-1}]^\top \in \mathbb{R}^{mp}$
- 线性动力学 $x_{t+1} = Ax_t + Bu_t$ (天然稳定)
- RG 退化为 $v_t = r_t$ (无额外约束修正)
- 稳态代价 $L_t^s(v) = L_t(v, \dots, v)$

得到的 Regret 界:

$$R_T^{\text{OCO-M}} \leq C_0 + R_T^{\text{OCO}} + C_{\text{PL}} R_T^{\text{PL}}$$

意义: OCO-M 是本文框架的特例。带切换代价 $\|u_t - u_{t-1}\|^2$ 的在线学习问题也被覆盖。

数值实验：非线性化学反应器

系统：连续搅拌釜式反应器 (CSTR)，2 维非线性动力学

$$\begin{bmatrix} \dot{c}_t \\ \dot{T}_t \end{bmatrix} = \begin{bmatrix} \frac{1}{\tau_f}(x_f - c_t) - kc_te^{-\frac{M}{T_t}} \\ \frac{1}{\tau_f}(T_f - T_t) + kc_te^{-\frac{M}{T_t}} - \alpha_f u_t(T_t - x_c) \end{bmatrix}$$

代价函数：

$$L_t(x, u) = q_t \|c_t - c_t^{\text{des}}\|^2 + u^2$$

其中 $q_t \in [50, 250]$ 和 $c_t^{\text{des}} \in [0.25, 0.65]$ 时变且未知。

对比实验：

- 2 种 OCO 算法：OGD vs. Prev. Opt.
- 2 种安全集： $\mathcal{O}_{\text{fix}}$ (常数) vs. $\mathcal{O}_{\text{var}}$ (可变)

实验结果与性能对比

组合	Norm. Regret	计算时间 [μ s]
OGD + $\mathcal{O}_{\text{fix}}$	100.00%	57 ± 2
OGD + $\mathcal{O}_{\text{var}}$	9.85%	189 ± 275
Prev. opt. + $\mathcal{O}_{\text{fix}}$	99.92%	57 ± 2
Prev. opt. + $\mathcal{O}_{\text{var}}$	9.85%	184 ± 273

关键发现：

- $\mathcal{O}_{\text{var}}$ （更大安全集）大幅降低 regret，但计算时间略增
- OGD 与精确最优之间性能差异可忽略
- 所有组合计算时间均在微秒级，适合实时控制
- 模块化优势：可灵活权衡计算效率与闭环性能

总结与展望

本文贡献：

1. 提出了模块化的 OCO-RG 框架：OCO + RG + 反馈控制
2. 适用于非线性系统且保证严格约束满足
3. 不限于特定算法，涵盖几乎所有的 OCO 和 RG
4. Regret 上界： $R_T \leq C_0 + R_T^{\text{OCO}} + C_{\text{PL}} R_T^{\text{PL}}$
5. 证明了线性依赖的最优性
6. 对 Q-线性收敛算法，达到已知的理论下界

局限性：假设系统模型精确已知，无不确定性。

未来方向：

- 鲁棒化：处理模型不确定性和扰动
- 改进 path length 的 regret 界（次线性？）

核心公式总结

1. 系统动力学: $x_{t+1} = f(x_t, u_t), \quad (x_t, u_t) \in \mathcal{Z}$
2. 闭环: $u_t = g(x_t, v_t), \quad x_{t+1} = f_g(x_t, v_t)$
3. 指数稳定性: $\|\phi(x, v, t) - h(v)\| \leq c\|x - h(v)\|\rho^t$
4. 稳态 OCO: $\min \sum L_t^s(r_t), \quad L_t^s(v) = L_t(h(v), g(h(v), v))$
5. Scalar RG: $v_t = v_{t-1} + \kappa_t(r_t - v_{t-1}), \quad \kappa_t = \arg \max_{\alpha \in [0,1]} \alpha \text{ s.t. } (x_t, \dots) \in \mathcal{O}$
6. Regret 界: $R_T \leq C_0 + R_T^{\text{OCO}} + C_{\text{PL}} R_T^{\text{PL}}$
7. 最优 Regret 界: $R_T \leq C_0 + \tilde{C} \sum \|\theta_t - \theta_{t-1}\|$ (Q-线性收敛时)

谢谢!