

Online Convex Optimization for Constrained Control of Nonlinear Systems

在线凸优化与参考调节器：非线性系统的约束控制

Hazhy

Paper Review

2026-05-28

论文信息

- **标题:** Online convex optimization for constrained control of nonlinear systems
- **作者:** Marko Nonhoff, Johannes Köhler, Matthias A. Müller
- **期刊:** Automatica 188 (2026) 112916
- **机构:** Leibniz University Hannover & ETH Zürich
- **关键词:** Online convex optimization, Control of constrained systems, Nonlinear systems, Dynamic regret, Reference governor

研究动机：为什么需要 OCO + 控制？

核心挑战：

- 代价函数 $L_t(x, u)$ 是时变且先验未知的
- 系统具有非线性动力学和状态/输入约束
- 必须在每步仅基于历史信息做出决策

现有方法不足：

- Nonstochastic Control：仅限于线性系统、扰动抑制
- Feedback Optimization：仅保证渐近约束满足
- 已有 OCO-based 方法：受限于特定算法，regret 界次优

本文贡献：模块化的 OCO-RG 框架，适用于非线性系统，保证严格约束满足，达到最优 regret 界

问题建模：非线性的在线最优控制

非线性动力学系统：

$$x_{t+1} = f(x_t, u_t), \quad t \in \mathbb{N}$$

- $x_t \in \mathbb{R}^n$ ：系统状态
- $u_t \in \mathbb{R}^m$ ：控制输入

约束条件：

$$(x_t, u_t) \in \mathcal{Z}, \quad t \in \mathbb{N}$$


在线最优控制问题（OCO 视角）：

$$\min_{u_0, \dots, u_T} \sum_{t=0}^T L_t(x_t, u_t) \quad \text{s.t. } x_{t+1} = f(x_t, u_t), (x_t, u_t) \in \mathcal{Z}$$

关键难点： L_t 在第 t 步完成后才被揭示，决策 u_t 只能依赖 $L_0, \dots, L_{t-1}$ 和状态 x_t 。

OCO-RG 框架：三大模块

核心思想：将在线优化与约束控制解耦，通过模块化设计实现灵活性和理论保证。



三大组件：

1. **OCO 算法：**基于历史代价计算期望参考 r_t
2. **参考调节器 (RG)：**修正 r_t 为 v_t ，确保约束满足
3. **稳定反馈控制器：** $u_t = g(x_t, v_t)$ ，跟踪修正后的参考

核心假设：稳态映射与稳定性

Assumption 1 —— 稳态映射：

$$h(v) = f(h(v), g(h(v), v)), \quad \forall v \in \mathbb{R}^o$$

参考输入 v 参数化系统的稳态。线性系统 $f(x, u) = Ax + Bu$ 下： $h(v) = (I_n - AK)^{-1}Bv$ 。标准假设，广泛使用。

Assumption 2 —— Lipschitz 连续性：

$$\|f_g(x, v) - f_g(\tilde{x}, \tilde{v})\| \leq \ell_f \|(x, v) - (\tilde{x}, \tilde{v})\|, \quad \text{类似地 } g, h$$

Assumption 3 —— 指数稳定性：

$$\|\phi(x, v, t) - h(v)\| \leq c\|x - h(v)\|\rho^t, \quad \rho \in [0, 1), \quad c \geq 1$$

关键保证： 闭环系统指数收敛到稳态，这是 regret 分析的基础。

参考调节器 (RG): 安全屏障

Assumption 4 —— 安全集 $\mathcal{O}$:

$$(x, v) \in \mathcal{O} \implies (\phi(x, v, t), v) \in \mathcal{Z}_g, \forall t \in \mathbb{N}$$

$\mathcal{O}$ 是前向不变的: 一旦进入, 恒定参考信号下永不会违反约束。

Assumption 5 —— RG 行为:

$$\begin{cases} v_t = r_t, & \text{if } r_t \in \mathcal{O}_v(x_t) \\ \lVert v_t - v_{t-1} \rVert \geq \kappa_t, \lVert r_t - v_t \rVert \leq (1 - \delta(\kappa_t)) \lVert r_t - v_{t-1} \rVert, & \text{otherwise} \end{cases}$$

Scalar RG (最常用):

$$\begin{aligned} \kappa_t &= \arg \max_{\alpha \in [0,1]} \alpha \text{ s.t. } (x_t, v_{t-1} + \alpha(r_t - v_{t-1})) \in \mathcal{O} \\ v_t &= v_{t-1} + \kappa_t(r_t - v_{t-1}) \end{aligned}$$

OCO 算法：在线跟踪时变最优

稳态代价函数：

$$L_t^s(v) := L_t(h(v), g(h(v), v))$$

简化的 OCO 问题：

$$\min_{r_0, \dots, r_T \in \mathcal{S}_v} \sum_{t=0}^T L_t^s(r_t)$$

关键简化：通过稳态映射 h ，将带动力学的控制问题转化为标准 OCO 问题！

最优参考 (benchmark, 仅用于分析)：

$$\theta_t := \arg \min_{v \in \mathcal{S}_v} L_t^s(v)$$

Definition 1 —— OCO 的 Dynamic Regret 和 Path Length：

$$R_T^{\text{OCO}} := \sum_{t=0}^T [L_t^s(r_t) - L_t^s(\theta_t)], \quad R_T^{\text{PL}} := \sum_{t=1}^T \|r_t - r_{t-1}\|$$

注意：Path length R_T^{PL} 在 regret 界中起关键作用！

完整算法：OCO-RG Framework

Algorithm 1: The OCO-RG Framework

for $t \in \mathbb{N}$ do

Given measurement x_t

$r_t = \mathcal{A}_{\text{OCO}}(\mathcal{I}_t)$;

// OCO 计算期望参考

$v_t = \text{RG}(x_t, r_t)$;

// RG 修正以确保安全

 Apply $u_t = g(x_t, v_t)$;

// 反馈控制器执行

信息集: $\mathcal{I}_t := \{r_0, \dots, r_{t-1}, L_0, \dots, L_{t-1}\}$

模块化优势:

- OCO 算法可任意替换 (OGD、Frank-Wolfe、二阶方法等)
- RG 可任意替换 (Scalar RG、Command Governor 等)
- 控制器可任意替换 (满足指数稳定性即可)

辅助工具：Lyapunov 函数与参考变化的影响

Lemma 1 —— Lyapunov 函数存在性：

$$\gamma_1 \|x - h(v)\| \leq V(x, v) \leq \gamma_2 \|x - h(v)\|$$

$$V(f_g(x, v), v) - V(x, v) \leq -\gamma_3 \|x - h(v)\|$$

$$|V(x, v) - V(x, \tilde{v})| \leq \ell_v \|v - \tilde{v}\|$$

Lemma 2 —— 参考变化的累积影响：

$$V(x_{\tau_2}, v_{\tau_2}) \leq \tilde{\rho}^{\tau_2 - \tau_1} V(x_{\tau_1}, v_{\tau_1}) + \ell_v \sum_{i=\tau_1+1}^{\tau_2} \|v_i - v_{i-1}\| \tilde{\rho}^{\tau_2 - i}$$

物理意义：当参考 v 改变时，Lyapunov 函数受两项影响——旧状态的指数衰减 + 参考变化累积。

Lemma 3: 平均收敛保证

核心问题: RG 可能在多步内阻止参考更新 ($v_t \neq r_t$), 我们需要保证”平均而言”参考在推进。

Lemma 3 —— 有限时间平均收敛:

$$\exists M \in \mathbb{N}, \delta \in (0, 1] \text{ s.t. } \prod_{i=t}^{t+M} (1 - \delta(\kappa_i)) \leq 1 - \delta$$

其中

$$\kappa_i = \begin{cases} \delta^{-1}(\|v_i - v_{i-1}\|), & \text{if } r_i \neq v_i \\ 0, & \text{otherwise} \end{cases}$$

直觉: 在任意 M 步窗口内, RG 至少推进了”一定量”的参考更新。这是连接 RG 行为和 OCO 性能的关键桥梁。

主定理: Dynamic Regret 上界

Theorem. 设 *Assumptions 1–6* 成立。闭环系统满足约束 $(x_t, u_t) \in \mathcal{Z}$ 对所有 $t \in \mathbb{N}$ 。且动态 regret 满足:

$$R_T \leq C_0 + R_T^{OCO} + C_{PL} R_T^{PL}$$

其中

$$C_{PL} = \ell_s \frac{2M + \delta}{\delta} + \ell(1 + \ell_g) \frac{\ell_V}{\gamma_1(1 - \tilde{\rho})},$$
$$C_0 = \ell(1 + \ell_g) \frac{\gamma_2}{\gamma_1(1 - \tilde{\rho})} (\|x_0 - h(\theta_0)\| + \ell_h \|v_0 - \theta_0\|)$$

解释: 框架的 regret 被 OCO 算法本身的 regret $\mathbf{R}_T^{OCO}$ 和 path length $\mathbf{R}_T^{PL}$ 线性地控制。常数取决于 RG 的设计参数 (M, δ) 和控制器收敛速度 $(\tilde{\rho})$ 。

Proposition 2: 线性依赖的最优性

问题: 主定理中 regret 对 R_T^{OCO} 的线性依赖能否改进为次线性?

Theorem (Proposition 2). 对任意控制算法 $u_t = \mathcal{A}(x_0, \dots, x_t, u_0, \dots, u_{t-1}, L_0, \dots, L_{t-1})$ 和任意 OCO 算法 $r_t = \mathcal{A}_{\text{OCO}}(\mathcal{I}_t)$, 存在一系列强凸且 Lipschitz 连续的代价函数 L_t , 使得:

$$R_T(x_0, u_0, \dots, u_T) \geq R_T^{\text{OCO}}(r_0, \dots, r_T)$$

证明思路: 选择 $L_t(x, u) = \left\| \begin{bmatrix} x - h(r_t) \\ u - g(h(r_t), r_t) \end{bmatrix} \right\|^2$, 则 $L_t^s(r_t) = 0$ 而 $L_t(x_t, u_t) \geq 0$, 导致 $R_T \geq R_T^{\text{OCO}}$ 。

结论: 线性上界不可改进, 是最优的。

推论：Q-线性收敛 OCO 算法

Proposition 1 —— Q-线性收敛 $\implies$ 有界 Path Length:

$$\|r_t - \theta_{t-1}\|_S \leq \lambda \|r_{t-1} - \theta_{t-1}\|_S, \quad \lambda \in [0, 1)$$

$\implies R_T^{\text{OCO}}$ 和 R_T^{PL} 都线性地被 $\sum \|\theta_t - \theta_{t-1}\|$ 控制。

Corollary. 若 OCO 算法 Q-线性收敛，则：

$$R_T \leq C_0 + (\tilde{C}_{\text{OCO}} + C_{\text{PL}} \tilde{C}_{\text{PL}}) \sum_{t=1}^T \|\theta_t - \theta_{t-1}\|$$

这是一个最优界！Li et al. (2019) 证明 $\sum \|\theta_t - \theta_{t-1}\|$ 是 regret 的下界。本文在非线性约束系统上达到了与线性系统相同的最优界。

满足条件的算法：Projected OGD（弱拟强凸代价）、Prev. Opt. ($\lambda = 0$) 等。

Remark 3: 与 OCO with Memory 的联系

OCO-M 问题: 代价函数可依赖过去 p 步的决策

$$\min_{\{u_t\}} \sum_{t=0}^T L_t(u_{t-p}, \dots, u_t) \quad \text{s.t. } u_t \in \mathcal{U}$$

转化为 OCO-RG 框架:

- 定义状态 $x_t = [u_{t-p} \cdots u_{t-1}]^\top \in \mathbb{R}^{mp}$
- 线性动力学 $x_{t+1} = Ax_t + Bu_t$ (天然稳定)
- RG 退化为 $v_t = r_t$ (无额外约束修正)
- 稳态代价 $L_t^s(v) = L_t(v, \dots, v)$

得到的 Regret 界:

$$R_T^{\text{OCO-M}} \leq C_0 + R_T^{\text{OCO}} + C_{\text{PL}} R_T^{\text{PL}}$$

意义: OCO-M 是本文框架的特例。带切换代价 $\|u_t - u_{t-1}\|^2$ 的在线学习问题也被覆盖。

数值实验：非线性化学反应器

系统：连续搅拌釜式反应器 (CSTR)，2 维非线性动力学

$$\begin{bmatrix} \dot{c}_t \\ \dot{T}_t \end{bmatrix} = \begin{bmatrix} \frac{1}{\tau_f}(x_f - c_t) - kc_te^{-\frac{M}{T_t}} \\ \frac{1}{\tau_f}(T_f - T_t) + kc_te^{-\frac{M}{T_t}} - \alpha_f u_t(T_t - x_c) \end{bmatrix}$$

代价函数：

$$L_t(x, u) = q_t \|c_t - c_t^{\text{des}}\|^2 + u^2$$

其中 $q_t \in [50, 250]$ 和 $c_t^{\text{des}} \in [0.25, 0.65]$ 时变且未知。

对比实验：

- 2 种 OCO 算法：OGD vs. Prev. Opt.
- 2 种安全集： $\mathcal{O}_{\text{fix}}$ (常数) vs. $\mathcal{O}_{\text{var}}$ (可变)

实验结果与性能对比

组合	Norm. Regret	计算时间 [μ s]
OGD + $\mathcal{O}_{\text{fix}}$	100.00%	57 ± 2
OGD + $\mathcal{O}_{\text{var}}$	9.85%	189 ± 275
Prev. opt. + $\mathcal{O}_{\text{fix}}$	99.92%	57 ± 2
Prev. opt. + $\mathcal{O}_{\text{var}}$	9.85%	184 ± 273

关键发现：

- $\mathcal{O}_{\text{var}}$ （更大安全集）大幅降低 regret，但计算时间略增
- OGD 与精确最优之间性能差异可忽略
- 所有组合计算时间均在微秒级，适合实时控制
- 模块化优势：可灵活权衡计算效率与闭环性能

总结与展望

本文贡献：

1. 提出了模块化的 OCO-RG 框架：OCO + RG + 反馈控制
2. 适用于非线性系统且保证严格约束满足
3. 不限于特定算法，涵盖几乎所有的 OCO 和 RG
4. Regret 上界： $R_T \leq C_0 + R_T^{\text{OCO}} + C_{\text{PL}} R_T^{\text{PL}}$
5. 证明了线性依赖的最优性
6. 对 Q-线性收敛算法，达到已知的理论下界

局限性：假设系统模型精确已知，无不确定性。

未来方向：

- 鲁棒化：处理模型不确定性和扰动
- 改进 path length 的 regret 界（次线性？）

核心公式总结

1. 系统动力学: $x_{t+1} = f(x_t, u_t), \quad (x_t, u_t) \in \mathcal{Z}$
2. 闭环: $u_t = g(x_t, v_t), \quad x_{t+1} = f_g(x_t, v_t)$
3. 指数稳定性: $\|\phi(x, v, t) - h(v)\| \leq c\|x - h(v)\|\rho^t$
4. 稳态 OCO: $\min \sum L_t^s(r_t), \quad L_t^s(v) = L_t(h(v), g(h(v), v))$
5. Scalar RG: $v_t = v_{t-1} + \kappa_t(r_t - v_{t-1}), \quad \kappa_t = \arg \max_{\alpha \in [0,1]} \alpha \text{ s.t. } (x_t, \dots) \in \mathcal{O}$
6. Regret 界: $R_T \leq C_0 + R_T^{\text{OCO}} + C_{\text{PL}} R_T^{\text{PL}}$
7. 最优 Regret 界: $R_T \leq C_0 + \tilde{C} \sum \|\theta_t - \theta_{t-1}\|$ (Q-线性收敛时)

谢谢!

Temporary page!

$\text{\LaTeX}$ was unable to guess the total number of pages correctly. As there was some unprocessed data that should have been added to the final page this extra page has been added to receive it. If you rerun the document (without altering it) this surplus page will go away, because $\text{\LaTeX}$ now knows how many pages to expect for this document.